

· 'Norm'은 벡터, 행렬, 텐서의 '크기'를 의미하는 값이다.

· Machine learning model의 weight norm은
해당 모델의 복잡도를 의미한다.

② L1 Regularization (Lasso)

Regularization은 통상적으로 L1과 L2 regularization으로 나뉘지게 된다.

앞서 살펴본 수식은 L2 regularization에 속하고,

L1 regularization은 2차항 대신에 1차항이 오며, 식은 아래와 같다.

$$C = C_0 + \frac{\lambda}{n} \sum_w |w|$$

↑ 원래의 cost function

'w'에 대해
편미분 하면,

앞서 살펴본 것과 마찬가지로 가중치 w에 대해서 편미분을 수행하면,
결과적으로는 새로운 가중치는 아래와 같이 결정이 된다.

$$w \rightarrow w' = w - \frac{\eta \lambda}{n} \text{sgn}(w) - \eta \frac{\partial C_0}{\partial w}$$

learning rate

결과적으로 위 식을 보면,

(weight 값 자체를 줄이는 것이 아니라)

'w의 부호에 따라 상수 값을 빼주는 방식'으로 regularization을 수행한다.

↑ 음수면 '-1', 양수면 '1'을 뺀다.

↑ 이에 따라, 원래 w 값의 절대값이 작아짐.

① L2 Regularization (Ridge)

Regularization은 (정확하게 표현하면, L2 regularization은) 아래의 수식으로 표현할 수 있다.

$$C = C_0 + \frac{\lambda}{2n} \sum_w w^2$$

위 수식에서 C_0 는 원래의 cost function이며,

n 은 훈련 데이터의 개수, λ 는 regularization 변수, w 는 가중치를 나타낸다.

λ 는 regularization 변수, w 는 가중치를 나타낸다.

위 식처럼 regularization 항목이 들어가면,

학습의 방향이 단순히 C_0 값이 작아지는 방향으로만 진행되는 것이 아니라,

w 값들 역시 최소가 되는 방향으로 진행을 하게 된다.

이렇게 정의된 cost function을 가중치 w 에 대해서 편미분을 수행하면, 결과적으로는 새로운 가중치는 아래와 같이 결정이 된다.

$$\begin{aligned} w &\rightarrow w - \eta \frac{\partial C_0}{\partial w} - \frac{\eta \lambda}{n} w = w - \frac{\eta \lambda}{n} \cdot w - \eta \frac{\partial C_0}{\partial w} \\ &= \left(1 - \frac{\eta \lambda}{n}\right) w - \eta \frac{\partial C_0}{\partial w} \end{aligned}$$

위 식에서 $(1 - \eta \lambda / n)w$ 는

원래의 w 값에 $(1 - \eta \lambda / n)$ 항목을 곱한 형태가 되기 때문에

값이 작아지는 방향으로 진행을 하게 된다.

원래 w 값의 "절대값"이 작아질.

w 에 대해
편미분 하면,